Модерни техники за паралелизъм и асинхронност в C++ Thread Pools, Coroutines и Publisher/Subscriber Pattern

Алекс Цветанов, КСИ, ФКСТ

Паралелно програмиране

22 октомври 2025 г.

План на лекцията

Увод: Паралелизъм vs Асинхронност Thread Pools

Концепция

Защо е необходим?

Предизвикателства

Lock-Free Queues

Примерна имплементация

Coroutines

Концепция

Как работят и защо са по-евтини?

Предизвикателства

Примерна имплементация

Publisher/Subscriber Pattern

Концепция

Приложения

Предизвикателства

Примерна имплементация

Паралелизирано разпращане

Комбиниране на техниките Заключение

Мотивация

Защо е важно?

- Съвременните СРИ имат множество ядра
- ► I/O операциите блокират нишки
- Нуждата от high-throughput системи
- Скалируемост и ефективност

Нашият фокус днес:

- 1. Thread Pools (паралелизъм)
- 2. Coroutines (асинхронност)
- 3. Publisher/Subscriber (комуникация)
- 4. Lock-free структури
- 5. Практически имплементации

Как да използваме ресурсите оптимално?


Паралелизъм vs Асинхронност



Thread Pools: истински паралелизъм (multiple cores)

Coroutines: кооперативна многозадачност (single core OK)

Thread Pool: Концепция



Идея: Фиксиран брой worker нишки, които обработват задачи от споделена опашка

Предимства:

- ▶ Контрол върху броя нишки
- Преизползване на ресурси
- ▶ По-добра производителност

Защо Thread Pool? Цената на създаване на нишки

Проблем: Създаването и унищожаването на std::thread обекти е скъпа операция! Thread Pool подход:

Наивен подход:

```
// Еднократно създаване
   ThreadPool pool(
       std::thread::
       hardware_concurrency()
   // Многократно използване
   for (auto& task : tasks) {
       pool.enqueue([&task]() {
           process(task);
11
       });
  pool.wait_all();
   // Предимства:
  // 1. Нишките се създават веднъж
  // 2. Преизползване на ресурси
  // 3. Контролиран паралелизъм
  // 4. По-добра cache locality
```

Benchmark: Създаване на 1000 нишки $\approx 50\text{-}100 \text{ms}$, Thread Pool $\approx 1\text{-}2 \text{ms}$

Overhead на създаване на нишки



Заключение: Thread Pool e 50x по-бърз за множество малки задачи!


Предизвикателство: Синхронизация на опашката

Проблем: Споделена опашка изисква lock за защита от race conditions

```
class ThreadPool {
       std::queue<std::function<void()>> tasks;
       std::mutex queue_mutex; // <-- KPHTHYHA CEKUHA
       std::condition_variable condition;
       void worker thread() {
           while (true) {
               std::function < void() > task:
10
                   std::unique_lock<std::mutex> lock(queue_mutex); // LOCK!
11
                   condition.wait(lock, [this] { return stop || !tasks.empty(); });
                   if (stop && tasks.empty()) return;
13
                   task = std::move(tasks.front());
14
                   tasks.pop():
               } // Unlock TVK
16
               task(): // Изпълнение извън lock-a
17
18
19
```

Bottleneck: Всички нишки се конкурират за един mutex!

Проблеми със standard mutex



Contention: 4 нишки чакат, само 1 работи!

Последици:

- Context switching
- Cache invalidation
- ► Намалена throughput при много нишки

Lock-Free структури: Концепция

Идея: Използване на атомарни операции вместо mutex Lock-based: Lock-free:

- × Blocking
- × Contention
- \times Priority inversion
- × Deadlock риск
- ✓ По-лесна имплементация

- ✓ Non-blocking
- √ No contention
- √ Wait-free progress
- ✓ По-висока throughput
- × Сложна имплементация


Ключови техники:

- ► Compare-And-Swap (CAS): std::atomic::compare_exchange_weak
- Memory ordering: memory_order_acquire, memory_order_release
- ABA problem решения (tagged pointers, hazard pointers)

Lock-Free Queue: Концепция

```
template < typename T>
   class LockFreeQueue {
       struct Node {
           std::shared ptr<T> data:
 4
           std::atomic<Node*> next:
           Node() : next(nullptr) {}
       };
       std::atomic<Node*> head:
       std::atomic < Node *> tail;
   public:
11
       void enqueue(T value) {
12
           auto new_node = new Node();
13
           new_node ->data = std::make_shared <T>(std::move(value));
14
           Node * old tail = tail.load(std::memory order relaxed):
15
           while (!tail.compare_exchange_weak(old_tail.new_node.
16
                   std::memory_order_release, std::memory_order_relaxed)) {
17
               // Retry ако друга нишка промени tail
18
19
           old_tail->next.store(new_node. std::memory_order_release);
20
21
       std::shared_ptr<T> dequeue() {
           Node * old_head = head.load(std::memorv_order_acquire);
23
           while (old head && !head.compare exchange weak(old head.
24
                   old_head->next.load(), std::memory_order_release)) {
               // Retry
26
           return old head ? old head ->data : nullptr:
28
29
   };
```

Lock-Free vs Lock-Based: Performance




Забележка: Lock-free структури scaling-ват много по-добре!

Thread Pool c Lock-Based Queue

```
class ThreadPool {
       std::vector<std::thread> workers:
       std::queue<std::function<void()>> tasks;
       std::mutex queue mutex:
       std::condition_variable condition;
       bool stop = false;
   public:
 9
       ThreadPool(size t threads) {
10
            for (size_t i = 0; i < threads; ++i) {</pre>
11
                workers.emplace_back([this] {
                    while (true) {
13
                        std::function < void() > task;
14
15
                             std::unique_lock<std::mutex> lock(queue_mutex);
16
                             condition.wait(lock, [this] {
17
                                 return stop || !tasks.emptv();
18
                            1):
19
                            if (stop && tasks.emptv()) return;
20
                            task = std::move(tasks.front());
21
                             tasks.pop():
23
                        task(): // Изпълнение извън lock-a
24
                }):
26
       // enqueue(), destructor...
   };
```

Coroutines: Какво са?

Определение: Функции, които могат да suspend-ват и resume-ват изпълнението си



Ключови думи в C++20:

- ▶ co_await suspend и чакане на резултат
- ▶ co_yield връщане на междинна стойност
- ► co_return завършване на coroutine

Threads vs Coroutines

Threads (OS-level):

- Управлявани от ОС
- Преемптивен scheduling
- ► Тежки (MB stack)
- ► Context switch \approx 1-10 μ s
- Паралелно изпълнение
- Използват множество ядра

Coroutines (user-level):

- ▶ Управлявани от програмата
- ▶ Кооперативен scheduling
- Леки (KB state)
- ► Context switch \approx 10-100ns
- ▶ Конкурентно, не паралелно
- Едно ядро (освен ако...)

Идеално: Coroutines за I/O, Threads за CPU-intensive работа

Coroutines: Механизъм на работа

Традиционна функция:

- ► Stack frame се създава при извикване
- ▶ Изпълнение до return
- Stack frame се унищожава
- Невъзможно повторно влизане


Coroutine:

- ► Състоянието се съхранява в heap (coroutine frame)
- со_await запазва локални променливи и позиция
- Контролът се връща на caller-а
- ▶ По-късно се resume-ва от същата позиция

Защо са по-евтини от threads?

- 1. Bes system calls so context switching
- 2. Малко състояние (само локални променливи)
- 3. Без thread stack (1-2 MB спестени)
- 4. Compiler оптимизации (inline възможни)

Memory Layout: Thread vs Coroutine



Резултат: Можем да имаме милиони coroutines, но само стотици threads!

Предизвикателство: Dangling References и Pointers

ВАЖНО: Локални променливи в coroutine са БЕЗОПАСНИ (в coroutine frame)!

```
Task<int> safe_coroutine() {
   int local_var = 42; // OK! B coroutine frame
   co_await some_async_operation();
   return local_var; // BE3OUACHO!
}
```

Проблем 1: Указатели/референции към ВЪН от coroutine

Предизвикателство: Dangling References и Pointers

Проблем 2: Referencing локални променливи от caller; Lambda capture by reference

```
void caller() {

std::vector<int> data = {1, 2, 3, 4, 5};

auto task = [&data]() -> Task<void> { // Capture by reference!

co_await async_operation();
 // data e na stack-a na caller()
 // Axo caller() приключи преди resume -> CRASH!

for (int x : data) { std::cout << x; } // BUS ERROR!

}();

// caller() завършва, data се унищожава
// но coroutine все още го реферира!

// но coroutine все още го реферира!
```

Обобщение:

- \checkmark Локални променливи В coroutine → coroutine frame (SAFE)
- imes Указатели/референции КЪМ външни данни o dangling (DANGEROUS)
- ✓ Използвайте capture by value: [data] вместо [&data]

Решение: Как да поставим данни в coroutine frame?

Правило: Всички променливи дефинирани в coroutine тяло автоматично се съхраняват в heap-allocated coroutine frame

Грешно (stack reference):

```
Task < void > bad_example() {
       std::string temp = "data":
       std::string& ref = temp;
5
       co await switch context():
       // ref може да е невалиден!
8
       std::cout << ref:
9
10
     Външна промендива
   void caller() {
13
       int x = 42:
   auto task = [&x]() -> Task<void> {
14
15
           co_await something();
16
        // x e dangling reference!
17
           use(x):
18
      }():
19 }
```

Правилно (coroutine frame):

```
Task < void > good_example() {
       // Konwe B coroutine frame
       std::string data = "data";
       co await switch context():
       // data е винаги валиден
       std::cout << data:
10
   // Правилно capture
   void caller() {
       int x = 42:
       auto task = [x]() -> Task < void> {
           // x е копирано (by value)
16
           co_await something():
17
           use(x): // SAFE!
       1():
18
19 }
```

Ключът: Компилаторът автоматично премества локални променливи в coroutine frame. Проблемът идва от references/pointers към външни данни!

Техники за безопасно управление на данни

1. Копиране вместо referencing

```
Task<void> process(std::string data) {
    // by value = copy in frame
    co_await async_operation();
    use(data); // Safe
}
```

2. std::move за големи обекти

```
Task<void> process(std::vector<int> vec) {
    auto local_vec = std::move(vec);
    // Move s coroutine frame
    co_await async_operation();
    use(local_vec);
}
```

3. shared ptr за споделени данни

```
Task<void> process(std::shared_ptr<BigData> data) {

// shared_ptr копира контролния блок,

// не данните

co_await async_operation();

use(*data); // Safe - data e жив докато

// има reference

}
```

4. Promise type c custom allocation

```
struct promise_type {
    void* operator new(size_t size) {
        // Custom allocator sa coroutine frame
    return my_pool_allocator.allocate(size);
    }
    // Всички локални променливи + promise
    // отиват тук
    };
```

Предизвикателство: Debugging и Stack Traces

Проблем: Coroutines нямат традиционен stack trace

```
Task<void> level3() {
    co_await std::suspend_always{};
    throw std::runtime_error("Error!"); // Къде e stack trace-a?

    Task<void> level2() {
        co_await level3();
    }
}

Task<void> level1() {
        co_await level2();
}

Task<void> level1() {
        co_await level2();
}

Task<void> level1() {
        co_await level2();
}

// При exception, debugger показва само текущата coroutine,
// не целия "async call stack"
```

Решения:

- ▶ Използвайте coroutine-aware debuggers (LLDB, Visual Studio)
- ▶ Логване на входни/изходни точки
- ► Custom promise types c ⊤pacing


Проста Coroutine имплементация (C++20)

```
#include <coroutine>
   #include <iostream>
   template < typename T>
   struct Task {
       struct promise_type {
           T value;
 8
           Task get return object() {
 9
               return Task{std::coroutine_handlepromise_type>::from_promise(*this)};
10
11
           std::suspend never initial suspend() { return {}: }
12
           std::suspend_always final_suspend() noexcept { return {}; }
13
           void unhandled_exception() { std::terminate(); }
14
           void return value(T v) { value = v: }
15
       };
16
       std::coroutine_handle <promise_type > handle:
17
       T get() { return handle.promise().value: }
18
       ~Task() { if (handle) handle.destrov(): }
19
   Task < int > async_computation() {
21
       std::cout << "Starting...\n":
       co_await std::suspend_always{}: // Suspend TVK
       std::cout << "Resuming...\n":
24
       co return 42:
25
   int main() {
       auto task = async_computation(); // Стартира, спира на co_await
28
       task handle resume(); // Продължава изпълнението
       std::cout << "Result: " << task.get() << "\n";
30 }
```

Реален пример: Async I/O c Coroutines

```
Task < std::string > async_read_file(const std::string& filename) {
       // Simulate async file reading
       co_await async_open(filename);
       std::string content:
       while (true) {
           auto chunk = co_await async_read_chunk();
           if (chunk.empty()) break;
 9
           content += chunk:
10
11
       co_await async_close();
13
       co_return content;
14
15
   Task < void > process_files() {
17
       // Множество паралелни четения (но в една нишка!)
       auto file1 = async_read_file("data1.txt");
18
19
       auto file2 = asvnc_read_file("data2.txt");
20
       auto file3 = async read file("data3.txt"):
21
       // Чакаме всички
23
       auto content1 = co await file1:
24
       auto content2 = co await file2:
       auto content3 = co_await file3:
26
27
       // Обработка...
       std::cout << "Total size: " << content1.size() + content2.size() + content3.size();
29
```

Publisher/Subscriber: Design Pattern



Определение: Architectural pattern за асинхронна комуникация **Компоненти:**

- ▶ Publisher генерира събития/съобщения
- ► Subscriber регистрира интерес и обработва
- ► Event Broker посредник (loose coupling)

Защо Pub/Sub Pattern?

Проблеми на директната комуникация:

- Tight coupling между компоненти
- Трудно масштабиране
- Промяна в един компонент засяга много други

Предимства на Pub/Sub:

- ✓ Loose coupling publishers не знаят за subscribers
- ✓ Scalability добавяне на subscribers без промяна
- ✓ Flexibility динамична (не)регистрация
- ✓ Асинхронност non-blocking communication

vs Observer Pattern:

- ▶ Observer = synchronous, директна връзка
- Pub/Sub = asynchronous, чрез посредник (broker)

Къде се използва Pub/Sub?

Event-Driven Архитектури

- ► GUI Applications (button clicks, window events)
- ► Game engines (collision events, state changes)

Microservices Communication

- Distributed systems (RabbitMQ, Apache Kafka)
- Service orchestration

Real-Time Data Processing

- Stock market data feeds
- ▶ IoT sensor networks
- Log aggregation systems

Reactive Programming

- RxCpp (Reactive Extensions)
- Async data streams

Примери от практиката

Financial Trading System:

- 1. Market data feed (publisher)
- 2. Risk engine (subscriber)
- 3. Trading strategies (subscribers)
- 4. Compliance monitor (subscriber)
- 5. Logging system (subscriber)

Всички компоненти получават същите данни, но ги обработват различно

IoT Smart Home:

- 1. Temperature sensor (publisher)
- 2. Heating system (subscriber)
- 3. Mobile app (subscriber)
- 4. Data logger (subscriber)
- 5. Alert system (subscriber)

Едно събитие тригерва множество реакции

Предизвикателство 1: Гаранции за доставка

Проблем: Какво ако subscriber не получи съобщението?


Опции за доставка:

- 1. At-most-once "fire and forget"
 - ▶ Най-бързо, но може да се загуби
 - ▶ Подходящо за некритични данни (metrics)
- 2. **At-least-once** retry при неуспех
 - Може да има дубликати
 - Нуждае се от idempotent обработка
- 3. Exactly-once гарантирана еднократна доставка
 - Най-сложно, изисква транзакции
 - ► Критични системи (payments, medical)

Trade-off: Надеждност vs Performance

Предизвикателство 2: Backpressure

Проблем: Publisher генерира събития по-бързо, отколкото subscribers могат да обработят



Решения:

- ► Buffering c bounded queue
- ▶ Dropping (отпадане на стари съобщения)
- Throttling (забавяне на publisher-a)
- ► Паралелизация на subscribers (нашата тема!)

Предизвикателство 3: Ordering

Проблем: Запазване на реда на съобщенията при паралелна обработка

```
1 // Subscriber c thread pool може да получи: 2, 1, 3 // заради паралелна обработка!
```

Решения:

- 1. Single-threaded processing губим паралелизъм
- 2. Partition-based групи съобщения с гарантиран ред
- 3. Sequence numbers преподреждане след обработка
- 4. Per-key ordering само свързани съобщения се подреждат

Проста Pub/Sub имплементация

```
template < typename Event >
   class EventBroker {
       using Subscriber = std::function < void (const Event&) >;
       using SubscriberId = size t:
       std::unordered_map < SubscriberId, Subscriber > subscribers;
       std::mutex mutex;
       SubscriberId next id = 0:
10
   public:
11
       SubscriberId subscribe(Subscriber&& callback) {
12
            std::lock_guard<std::mutex> lock(mutex);
13
            auto id = next_id++;
14
            subscribers[id] = std::move(callback):
15
            return id;
16
17
18
       void unsubscribe(SubscriberId id) {
19
            std::lock_guard<std::mutex> lock(mutex);
20
            subscribers.erase(id):
21
23
       void publish (const Event& event) {
24
            std::lock_guard<std::mutex> lock(mutex);
25
            for (auto& [id. subscriber] : subscribers) {
26
                subscriber(event): // Синхронно извикване
27
28
29
   };
```

Асинхронна имплементация с Thread Pool

```
template < typename Event >
   class AsvncEventBroker {
       using Subscriber = std::function<void(const Event&)>:
       std::vector<Subscriber> subscribers:
       ThreadPool pool;
       std::mutex mutex:
 8
   public:
9
       AsyncEventBroker(size t num threads = std::thread::hardware concurrency())
10
           : pool(num_threads) {}
11
12
       void subscribe (Subscriber & callback) {
13
           std::lock_guard<std::mutex> lock(mutex);
14
           subscribers.push_back(std::move(callback));
15
16
17
       void publish(const Event& event) {
18
           std::lock guard<std::mutex> lock(mutex):
19
           // Всеки subscriber се обработва в отделна задача
20
           for (autok subscriber : subscribers) {
21
               pool.enqueue([subscriber.event]() {
22
                    subscriber(event): // Паралелно изпълнение!
               });
24
25
          // publish() не чака обработката
26
   }:
```

Предимство: Non-blocking publish(), паралелна обработка!

Паралелизация на subscriber dispatch


Проблем: Наивната имплементация има serialization bottleneck




Техники за оптимизация:

- Lock-free subscriber list (RCU Read-Copy-Update)
- Per-subscriber queue вместо centralized
- ► Wait-free publish операции
- ▶ Batch processing на множество събития

Сравнителна графика: Всички имплементации



Сравнителна графика: С++ имплементации




oneTBB:

std::execution:

```
template < auto Event, typename... Args >
bool Publisher::emit_async(std::
    execution::parallel_policy policy,
    Args&&... args) {
    auto* handler = get_handler < Event > ();
    std::for_each(policy,
    handler -> callbacks.begin(),
    handler -> callbacks.end(),
    [&](const auto& cb) {
        cb(std::forward < Args > (args)...);
    });
    return true;
}
```

Интеграция: Thread Pool + Coroutines + Pub/Sub



Hybrid подход:

- ► Thread Pool за паралелна обработка (CPU-intensive)
- Coroutines за I/O операции (networking, disk)
- Pub/Sub за декуплиране и организация

Кога какво да използваме?

Задача	Техника	Защо?
CPU-intensive	Thread Pool	Използва всички ядра
I/О операции	Coroutines	Ниски overhead, милиони connections
Event routing	Pub/Sub	Loose coupling
High-throughput	Lock-free + Pool	Минимизира contention
Mixed workload	Hybrid	Комбинира силни страни

Практически съвет:

- 1. Измерете bottleneck-овете (профилиране!)
- 2. Не оптимизирайте преждевременно
- 3. Комбинирайте техники според нуждите

Обобщение

Какво научихме днес:

1. Thread Pools

- Преизползване на нишки за ефективност
- Lock-based vs lock-free имплементации
- ► Цената на създаване на threads (50-100х!)

2. Coroutines

- Леки, кооперативни задачи
- ► Идеални за I/O-bound workloads
- ▶ 100х по-евтини от threads (KB vs MB)

3. Publisher/Subscriber

- ► Decoupling upes event broker
- Паралелизирано разпращане на съобщения
- Препратка към научна работа

4. Комбиниране

Hybrid архитектури за реални системи

Връзка с курса

Модул 2: Асинхронно програмиране с .NET

- ightharpoonup Лекция 2-2: Подходи за асинхронен код ightharpoonup Thread Pools (C++)
- ▶ Лекция 2-3: Async-await шаблон \rightarrow Coroutines (C++20)
- ightharpoonup Лекция 2-4: Паралелен достъп до данни ightharpoonup Lock-free structures
- ightharpoonup Лекция 2-1: Оптимизация и performance ightarrow Benchmarks (днес)

C++ vs .NET паралели:

- ▶ .NET Task Parallel Library ↔ C++ Thread Pool
- NET async/await ↔ C++ coroutines (co_await)
- ▶ .NET Concurrent Collections ↔ C++ lock-free queues
- ► .NET Events ↔ C++ Publisher/Subscriber pattern

Тази лекция разширява:

- Low-level имплементации на високо-ниво концепции
- Performance considerations (защо Thread Pool вместо threads?)
- Практически шаблони за комуникация (Pub/Sub)

Препоръчителна литература

Книги:

- "C++ Concurrency in Action" Anthony Williams
- ▶ "The Art of Multiprocessor Programming" – Herlihy & Shavit
- "Programming with POSIX Threads" David Butenhof

Papers & Talks:

- "Lock-Free Data Structures" Michael& Scott
- "RCU (Read-Copy-Update)" McKenney
- "Optimizing Asynchronous Event Dispatch in Modern C++ Publish/Subscribe Systems" – Alex Tsvetanov

Lock-Free Queue имплементации и talks:

- "User API and C++ Implementation of MPMC Lock Free Queue" – Erez Strauss, CppCon 2024
- "Building a Lock-free MPMC Queue for Tcmalloc" – Matt Kulukundis, CppCon 2021
- github.com/DNedic/lockfree Djordje Nedic, Pablo Duboue, Lennart Schierling

Online ресурси:

- cppreference.com coroutines, atomics, memory ordering
- preshing.com lock-free programming blog
- ▶ 1024cores.net Dmitry Vyukov's concurrency blog

Въпроси и дискусия

Въпроси?

Благодаря за вниманието!

Контакт: atsvetanov@tu-sofia.bg | GitHub: github.com/Alex-Tsvetanov